A Scientific gain / AUBC

Method	PyBaMM	AQM	FDTD	Reactor	IRP
Alg.-Only	0.12±0.01 7.3±0.4	0.09±0.01 5.1±0.3	0.14±0.01 8.5±0.5	0.11±0.01 6.7±0.3	0.10±0.01 5.8±0.2
Direct-LLM	0.21±0.01 19.2±0.6	0.17±0.01 14.3±0.5	0.24±0.02 22.6±0.7	0.19±0.01 16.2±0.4	0.18±0.01 13.7±0.4
Embed-GP	0.30±0.02 30.5±0.8	0.25±0.01 24.8±0.7	0.33±0.02 36.2±0.9	0.27±0.01 27.4±0.6	0.25±0.01 23.1±0.5
Janus	0.36±0.02 42.8±1.0	0.30±0.02 34.7±0.8	0.39±0.02 51.3±1.1	0.32±0.02 36.9±0.8	0.30±0.01 31.5±0.7
SpecRSI (ours)	**0.48**±0.02 **56.7**±1.2	**0.41**±0.02 **45.8**±1.0	**0.52**±0.02 **66.9**±1.3	**0.44**±0.02 **49.3**±1.0	**0.42**±0.02 **42.1**±0.9

B System scores (%, ↑)

Method	TB2.1	SWE-Pro	GPQA	AIME
D/H/M: data, harness, model				
Initial	23.6±0.7	10.3±0.5	71.2±0.8	55.0±0.6
Data-RSI	27.4±0.8	12.4±0.6	73.8±0.9	57.7±0.7
Harness-RSI	29.4±0.9	14.9±0.7	78.8±1.0	63.3±0.8
Model-RSI	27.0±0.8	14.0±0.6	75.4±0.9	59.3±0.7
Fixed D→M→H	30.3±0.9	15.3±0.7	79.4±1.0	64.3±0.8
Static router	30.8±1.0	14.9±0.7	79.6±1.1	64.0±0.9
MetaRSI-v1	31.9±1.0	19.5±0.8	83.8±1.1	68.3±0.9
SpecRSI (ours)	**33.5**±1.1	**21.7**±0.9	**86.1**±1.2	**71.2**±1.0
D+H: no model update				
MetaRSI-H	28.7±0.8	14.2±0.6	77.5±0.9	61.8±0.7
SpecRSI-H (ours)	**30.1**±0.9	**16.3**±0.7	**79.9**±1.0	**64.7**±0.8